



ulm university universität
uulm

**Fakultät für
Mathematik und
Wirtschafts-
wissenschaften**

Institut für Numerische
Mathematik

Cache-optimierte QR-Zerlegung

Bachelorarbeit an der Universität Ulm

Vorgelegt von:

Florian Krötz
florian.kroetz@uni-ulm.de

Gutachter:

Dr. Michael Lehn
Dr. Andreas Borchert

Betreuer:

Dr. Michael Lehn

2018

Fassung 30. April 2018

© 2018 Florian Krötz

Satz: PDF- \LaTeX 2 _{ε}

Inhaltsverzeichnis

1	Einleitung	1
1.1	Cache	1
1.2	Intel MKL	1
1.2.1	QR Anwendung oder so was	1
2	BLAS	2
2.1	Datenstruktur für Matrizen	2
2.2	Einige BLAS-Blasroutinen	3
2.2.1	Matrix-Matrix Produkt (gemm)	3
2.2.2	Matrix-Vector Produkt (gemv)	3
2.2.3	Rank1 update (ger)	4
2.2.4	Matrix-Matrix Produkt (trmm)	4
2.2.5	Matrix-Vector Produkt (trmv)	4
3	QR factorisation	5
3.1	QR-Zerlegung	5
	Definition	5
	Motivation	5
3.2	Householder-Transformation	6
3.2.1	Householder Vector	6
3.2.2	Apply vector	7
3.2.3	LAPACK QR	8
3.2.4	NUM1 Urban QR	8
3.3	QR Blocked	9
3.3.1	Calc Factor T larft	10
3.3.2	Apply H larfb	11
3.3.3	Iterativer Algorithmus	12
3.3.4	Rekursiver Algorithmus	12
4	Implementierung und Benchmarks	14
4.1	MKL Wrapper	14

Inhaltsverzeichnis

4.2 Benchmarks	14
A Quelltexte	15
Literaturverzeichnis	16

1 Einleitung

Für was brauch ich die QR?

Warum muss die schnell sein?

Was soll der Scheiß?

1.1 Cache

Wie funktioniert der Und warum Cache-Optimierung

1.2 Intel MKL

Kapitel über die Wichtigkeit der Intel MKL.

1.2.1 QR Anwendung oder so was

-LGS -Ausgleichsprobleme -QR-Verfahren

2 BLAS


2.1 Datenstruktur für Matrizen

Um vollbesetzte Matrizen zu speichern benötigt man eine Speicherfläche für alle Einträge der Matrix, Informationen wie die Einträge im Speicher organisiert sind und Informationen über die Größe der Matrix.


Es ist sinnvoll vollbesetzte Matrizen entweder Zeilen- oder Spaltenweise im Speicher abzuspeichern. Das bedeutet die Zeilen oder Spalten der Matrix liegen hintereinander im Speicher.

$$A = \begin{pmatrix} a_{1,1} & a_{1,2} & a_{1,3} \\ a_{2,1} & a_{2,2} & a_{2,3} \\ a_{3,1} & a_{3,2} & a_{3,3} \end{pmatrix} \in \mathbb{R}^{m \times n}$$

Matrix A Zeilenweise gespeichert



Matrix A Spaltenweise gespeichert



Eine Datenstruktur benötigt ein Zeiger auf eine Speicherfläche, Informationen ob die Matrix Zeilen- oder Spaltenweise gespeichert ist und die Dimension der Matrix.

So eine Datenstruktur könnte in C so aussehen.

```
1 struct Matrix {
```

```
2 double * data;  
3 std::ptrdiff_t incRow, incCol;  
4 std::size_t numRows, numCols;  
5 }
```

Für Intel MKL und LAPACK Routinen müssen die Matrizen zeilenweise gespeichert.

2.2 Einige BLAS-Blasroutinen

Im Folgenden werden einige BLAS-Routinen beschrieben, die bei der QR-Zerlegung benutzt werden. BLAS-Blasroutinen werden bei MKL und LAPACK nach folgendem Schema benannt. Der erste Buchstabe im Namen gibt an für welchen Datentype die Funktion implementiert wurde. Der rest zeigt an was die Funktion tut. Zum Beispiel "dgemm", das d zeigt an die Funktion ist für Doubles und "gemm" steht für das Matrix-Matrix Produkt.

2.2.1 Matrix-Matrix Produkt (gemm)

Die gemm Funktion berechnet das Matrix-Matrix Produkt. Der Funktion werden die Matrizen A , B und C und die Skalare α und β übergeben.

Die Funktion berechnet

$$C \leftarrow \beta C + \alpha AB \quad (2.1)$$

Falls $\beta = 0$ wird die Matrix C zuerst mit Nullen initialisiert. Falls C Einträge hat die NaN (Not a Number) sind, werden diese somit mit 0 überschrieben.

2.2.2 Matrix-Vector Produkt (gemv)

Die Funktion gemv berechnet das Matrix-Vector Produkt. Der Funktion wird die Matrix A die Vektoren x und y und die Skalare α und β übergeben.

Die Funktion berechnet

$$y \leftarrow \beta y + \alpha Ax \quad (2.2)$$

Falls $\beta = 0$ wird der Vektor y zuerst mit Nullen initialisiert. Falls y Einträge hat die NaN (Not a Number) sind, werden diese somit mit 0 überschrieben.

2.2.3 Rank1 update (ger)

Die Funktion `ger` berechnet ein dyadische Produkt aus den Vektoren x und y , skaliert die daraus resultierende Matrix mit α und addiert das Ergebnis auf A .// Der Funktion wird die Matrix A die Vektoren x und y und das Skalar α übergeben. Die Funktion berechnet

$$A \leftarrow A + \alpha xy^T \quad (2.3)$$

2.2.4 Matrix-Matrix Produkt (trmm)

Die Funktion `trmm` berechnet das Matrix-Matrix Produkt einer Dreiecksmatrix mit einer voll besetzten Matrix. Der Funktion wird die Dreiecksmatrix A , die Matrix B und das Skalar α übergeben. Außerdem werden Flags mit übergeben die anzeigen ob A eine obere oder unter Dreiecksmatrix ist, ob A eine strikte oder unipotente Dreiecksmatrix ist, ob A von links oder rechts auf B multipliziert werden soll und ob A transponiert werden soll.

Die Funktion berechnet

$$B \leftarrow \alpha * op(A) * B \quad \text{or} \quad B \leftarrow \alpha * B * op(A) \quad (2.4)$$

2.2.5 Matrix-Vector Produkt (trmv)

Die Funktion berechnet

$$x \leftarrow \alpha * A * x \quad \text{or} \quad x \leftarrow \alpha * A^T * x \quad (2.5)$$

3 QR factorisation

3.1 QR-Zerlegung

Definition

Eine Matrix $A \in \mathbb{R}^{m \times n}$, $m \geq n$ besitzt eine eindeutige QR-Zerlegung.

$$A = QR \quad (3.1)$$

mit einer orthogonalen Matrix $Q \in \mathbb{R}^{m \times m}$ und einer oberen Dreiecksmatrix $R \in \mathbb{R}^{n \times n}$ [2]

Eine QR Zerlegung kann mit einer Householder-Transformation berechnet werden.

Motivation

Lösung eines Minimierungsproblem

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|^2 \quad (3.2)$$

mit Matrix $A \in \mathbb{R}^{m \times n}$ mit $\text{rang}(A) = n < m$ für die eine QR Zerlegung existiert. R besitzt die Gestalt

$$R = \begin{pmatrix} * & * & * \\ & * & * \\ \hline & & * \\ & & 0 \end{pmatrix} = \begin{pmatrix} \hat{R} \\ \hline 0 \end{pmatrix}$$

\hat{R} stellt eine obere Dreiecksmatrix dar. Damit kann man das Minimierungs Problem

wie folgt modifizieren mit $A = QR$

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|^2 = \min_{x \in \mathbb{R}^n} \|Q^T(Ax - b)\|^2 = \min_{x \in \mathbb{R}^n} \|Rx - Q^T b\|^2 \quad (3.3)$$

Also löst

$$Rx = Q^T b \quad (3.4)$$

das Minimierungsproblem (3.2). Da R eine Dreiecksmatrix ist lässt sich (3.4) leicht mit Rückwärtseinsetzen lösen.

3.2 Householder-Transformation

Sei $v \in \mathbb{R}^n$ und $\tau \in \mathbb{R}$ dann wir die $n \times n$ Matrix

$$H = I - 2 \frac{vv^T}{v^T v} \quad (3.5)$$

als Householder-Transformation und der Vektor v als Householder-Vektor bezeichnet. Eine Householder-Transformation $H = I - 2 \frac{vv^T}{v^T v}$ ist orthogonal und symmetrisch. [2]

Die Householder-Transformation spiegelt den Vektor x auf die Achse x_1 . Dazu multipliziert man H von links auf x .

$$Hx = \alpha e_1 \quad (3.6)$$

mit $\alpha \in \mathbb{R}$ und e_1 erster kanonischer Einheitsvektor. Der Householder-Vektor steht senkrecht auf der Achse an der x gespiegelt wird.

Die Abbildung 3.1 veranschaulicht die Spiegelung der Vektors x and der gestrichelt eingezeichneten Ebene auf die x_1 Achse.

3.2.1 Householder Vector

Wie muss der Vektor v aussehen damit (3.6) gilt.




Abbildung 3.1: Beispiel Householder-Transformation mit $x = (-1, 2)^T$

Algorithmus 1 Housholder-Vector

```

 $A \in \mathbb{R}^{m \times n}$ 
for  $i = 0 : n$  do
     $[v, \tau] = \text{housevector}(A(i : m, i))$ 
     $w \leftarrow v^T * A$  (dgemv)
     $A \leftarrow \tau * v * w + A$  (dger)
    if  $i > m$  then
         $A(i + 1 : m, j) \leftarrow v(2 : m - i + 1)$ 
    end if
end for

```

3.2.2 Apply vector

Ein aufwändiges Matrix-Matrix Produkt kann bei der Anwendung der Housholder-Matrix $H = I - \tau vv^T$ auf die Matrix A umgangen werden, indem man geschickt Klammert.

$$HA = (I - \tau vv^T)A = A - \tau vv^T A = A - \tau v * (v^T * A)$$

Statt eines Matrix-Matrix Produkts, muss man nun nur ein Matrix-Vektor Produkt und ein dyadisches Produkt berechnen. Das Matrix-Vektor Produkt und das dyadische Produkt haben nur einen Aufwand von $O(n^2)$.

Das führt auf den Algorithmus 2.

Der Algorithmus 2 überschreibt die Matrix A mit R . Da R eine obere Dreiecksmatrix ist, werden unter der Diagonalen die Housholder-Vektoren gespeichert. A hat also

Algorithmus 2 Ungeblockte Housholder-Transformation

```

 $A \in \mathbb{R}^{m \times n}$ 
for  $i = 0 : n$  do
     $[v, \tau] = \text{housevector}(A(i : m, i))$ 
     $w \leftarrow v^T * A$  (dgemv)
     $A \leftarrow \tau * v * w + A$  (dger)
    if  $i > m$  then
         $A(i + 1 : m, j) \leftarrow v(2 : m - i + 1)$ 
    end if
end for

```

die Form

$$A = \begin{pmatrix} R & R & R \\ v_1 & R & R \\ v_1 & v_2 & R \\ v_1 & v_2 & v_3 \end{pmatrix}$$

3.2.3 LAPACK QR

Der von LAPACK benutzte Algorithmus [3]

$$\tau = \frac{\alpha - \beta}{\beta} \quad (3.7)$$

$$\alpha = A(i, i) \quad (3.8)$$

$$\beta = \text{sign}(\alpha) \left| \sqrt{\alpha^2 + \|x\|^2} \right| \quad (3.9)$$

$$x = A(i + 1 : m, i) \quad (3.10)$$

$$v = A(i + 1 : m, i) * \frac{1}{\alpha - \beta} \quad (3.11)$$

3.2.4 NUM1 Urban QR

Algorithmus aus Numerik 1




Abbildung 3.2: Partitionierung von A

$$v_1 = \frac{x - \alpha e_1}{x_1 - \alpha} \quad (3.12)$$

$$\alpha^2 = \|x\|^2 \quad (3.13)$$

3.3 QR Blocked

Ein geblockter Algorithmus ist sinnvoll um bei großen Matrizen den Cache optimal auszunutzen. Geblockte Alorighmus

$$\begin{aligned} H &= I - VTV^T \\ H^T &= I - VT^TV^T \\ H^T A_{bs,bs} &= A_{bs,bs} - VT^TV^T A_{bs,bs} \end{aligned}$$

Betrachte A geblockt, mit einer geeigneten Blockgröße bs .

$$A = \left(\begin{array}{c|c} A_{0,0} & A_{0,bs} \\ \hline A_{bs,0} & A_{bs,bs} \end{array} \right) \quad (3.14)$$

Die Abbildung 3.2 zeigt schematisch die Partitionierung von A.

Berechne nun QR Zerlegung für den Block $\begin{pmatrix} A_{0,0} \\ A_{bs,0} \end{pmatrix}$

$$\begin{pmatrix} A_{0,0} \\ A_{bs,0} \end{pmatrix} \leftarrow \begin{pmatrix} Q_{0,0} \setminus R_{0,0} \\ Q_{bs,0} \end{pmatrix} \quad (3.15)$$

Berechne $H(0) \dots H(bs)$ aus $Q_{0,0}$ und $Q_{bs,0}$ mit $H = I - V * T * V^T$.
Wende H^T auf $A_{0,bs}$ und $A_{0,bs}$ an.

$$\begin{pmatrix} A_{0,bs} \\ A_{0,bs} \end{pmatrix} \leftarrow H^T \begin{pmatrix} A_{0,bs} \\ A_{0,bs} \end{pmatrix} \quad (3.16)$$

Fahre mit $A_{0,bs}$ fort.

3.3.1 Calc Factor T larft

Die Funktion bekommt eine Dreiecksmatrix $V \in \mathbb{R}^{m \times k}$ einen Vektor $\tau \in \mathbb{R}^k$ und eine Matrix $T \in \mathbb{R}^{k \times k}$ übergeben. Die Funktion berechnet eine Dreiecksmatrix T so dass

$$H_1 H_2 \dots H_k = I - V T V^T \quad \text{mit} \quad H_i = I - \tau_i v_i v_i^T$$

Warum und wie das funktioniert wird hier beschreiben [1].

Versuch einer Herleitung

$$\begin{aligned} H_1 H_2 x &= (I - \tau_1 v_1 v_1^T)(I - \tau_2 v_2 v_2^T)x \\ &= (I - \tau_1 v_1 v_1^T - \tau_2 v_2 v_2^T - \tau_1 v_1 v_2^T \tau_2 v_2 v_2^T)x \\ &= x - \tau_1 v_1 v_1^T x - \tau_2 v_2 v_2^T x - \tau_1 \tau_2 v_1 (v_1^T v_2) v_2^T x \\ &= x - \tau_1 v_1 v_1^T x - \tau_2 v_2 v_2^T x - \tau_1 \tau_2 (v_1^T v_2) v_1 v_2^T x \end{aligned}$$

$$\begin{aligned}
 H_{1,2}x &= (I - VTV^T)x = x - VTV^Tx \\
 &= x - (v_1, v_2) \begin{pmatrix} a & b \\ 0 & c \end{pmatrix} \begin{pmatrix} v_1^T \\ v_2^T \end{pmatrix} x \\
 &= x - (v_1, v_2) \begin{pmatrix} a & b \\ 0 & c \end{pmatrix} \begin{pmatrix} v_1^Tx \\ v_2^Tx \end{pmatrix} \\
 &= x - (v_1, v_2) \begin{pmatrix} av_1^Tx + bv_2^Tx \\ cv_2^Tx \end{pmatrix} \\
 &= x - v_1(av_1^Tx + bv_2^Tx) - v_2(cv_2^Tx) \\
 &= x - av_1v_1^Tx - bv_1v_2^Tx - cv_2v_2^Tx
 \end{aligned}$$

3.3.2 Apply H larfb

Die Funktion `larfb` bekommt eine Dreiecksmatrix $V \in \mathbb{R}^{m \times k}$, eine Dreiecksmatrix $T \in \mathbb{R}^{k \times k}$ und eine Matrix $C \in \mathbb{R}^{m \times n}$ übergeben. Die Funktion wendet eine Block Reflector Matrix $H = C - VTV^T$ von rechts auf die Matrix C an. Mit einem weiteren Übergabeparameter kann angegeben werden ob die Block Reflector Matrix noch transponiert werden soll. Die Funktion berechnet also

$$C \leftarrow HC = C - VTV^TC \quad \text{oder} \quad C \leftarrow H^TC = C - VT^TV^TC$$

Die Abbildung 3.3 zeigt die Partitionierung der Matrix A für die Funktion `larfb`.

Falls $m > k$ werden die Matrizen V und C aufgeteilt in $V = \begin{pmatrix} V_1 \\ V_2 \end{pmatrix}$ und $C = \begin{pmatrix} C_1 \\ C_2 \end{pmatrix}$.

Dabei wird V genau so gewählt, dass $V_1 \in \mathbb{R}^{k \times k}$ der Dreiecksteil der Matrix und quadratisch ist und $V_2 \in \mathbb{R}^{m-k \times k}$ der Rest der Matrix. Die Matrix C wird in $C_1 \in \mathbb{R}^{k \times n}$ und $C_2 \in \mathbb{R}^{m-k \times n}$ aufgeteilt.

Die Aufteilung ist Notwendig da die BLAS-Funktion `trmm` (matrix-matrix product where one input matrix is triangular) nur für Quadratische Dreiecksmatrizen implementiert ist.

Im Fall $m = k$ ist die Aufteilung nicht Notwendig da V quadratisch ist.

$$\begin{aligned}
 &(C_1^T * V_1 * T * V_1^T)^T \\
 &V_1 * T^T * V_1^T * C_1
 \end{aligned}$$




Abbildung 3.3: Partitionierung vom A für larfb

Dies führt zu dem Algorithmus 3

Algorithmus 3 Block reflector anwenden

```

 $W \leftarrow C_1^T$  (copy)
 $W \leftarrow W * V_1$  (trmm)
if  $m > k$  then
     $W \leftarrow W + C_2^T * V_2$  (gemm)
end if
 $W \leftarrow W * T^T$  or  $W * T$  (trmm)
if  $m > k$  then
     $C_2 \leftarrow C_2 - V_2 * W^T$  (gemm)
end if
 $W \leftarrow W * V_1^T$  (trmm)
 $C_1 \leftarrow C_1 - W^T$ 
    
```

3.3.3 Iterativer Algorithmus

3.3.4 Rekursiver Algorithmus

e

Algorithmus 4 Iterativer Algorithmus

```
for i = 0 : n do
    QR = A;
    if i + ib > n then
        Calc T:  $H = I - VTV'$ 
        Apply H:  $A = H'A$ 
    end if
end for
```

4 Implementierung und Benchmarks

Irgend was über die HPC Bibliothek

4.1 MKL Wrapper

4.2 Benchmarks

A Quelltexte

In diesem Anhang sind einige wichtige Quelltexte aufgeführt.

```
1 #include <stdio.h>
2 int main(int argc, char ** argv) {
3     printf("Hallo HPC \n");
4     return 0;
5 }
```

Literaturverzeichnis

- [1] JOFFRAIN, Thierry ; LOW, Tze M. ; QUINTANA-ORTÍ, Enrique S. ; GEIJN, Robert van d. ; ZEE, Field G. V.: Accumulating Householder Transformations, Revisited. In: *ACM Trans. Math. Softw.* 32 (2006), Juni, Nr. 2, 169–179. <http://dx.doi.org/10.1145/1141885.1141886>. – DOI 10.1145/1141885.1141886. – ISSN 0098–3500
- [2] STEFAN A. FUNKEN, Karsten U.: *Einführung in die Numerische Lineare Algebra*. Ulm, Germany, 2016
- [3] TENNESSEE, Univ. of California B. o. ; LTD., NAG: *LAPACK unblocked QR*. <http://www.netlib.org/lapack/explore-3.1.1-html/dgeqr2.f.html>, 2006. – [Online; zugegriffen 31-01-2018]

Name: Florian Krötz

Matrikelnummer: 884948

Erklärung

Ich erkläre, dass ich die Arbeit selbständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet habe.

Ulm, den

Florian Krötz